

ДИСЦИПЛИНА	Базы данных и анализ промышленных данных
ИНСТИТУТ	Передовая инженерная школа
КАФЕДРА	Кафедра передовых технологий
ВИД УЧЕБНОГО МАТЕРИАЛА	Практическое занятие
ПРЕПОДАВАТЕЛЬ	Астафьев Р.У.
СЕМЕСТР	2 семестр, 2025 - 2026 гг.

Практическая работа 1

1. Основы математической статистики


Математическая статистика изучает методы сбора и обработки статистической информации для получения научных и практических выводов. Под статистической информацией подразумеваются первичные данные о состоянии различных явлений, формирующиеся в процессе статистического наблюдения, которые затем подвергаются систематизации, сводке, анализу и обобщению.

Примеры:

1. Социологические исследования. Ответы респондентов, являющиеся в данном случае первичными данными, помогают выявить тенденции, закономерности и особенности в поведении людей, их мнениях, отношениях и восприятии окружающего мира. Например, краткая аналитика из исследования стриминговых сервисов музыки:

Платную подписку оформляют чаще всего на «Яндекс.Музыке» (63%). Также 18% пользуются платно сервисом «VK Музыка», а 6% – «МТС Music». Несмотря на сложности с оплатой, 11% приобретают подписку на Apple Music, 6% – YouTube Music (например, оплачивают со счета мобильного телефона). Отметим, что 4% опрошенных обходят блокировку и продолжают пользоваться Spotify, и 1% – платформой Deezer, которая тоже ограничила доступ российским пользователям прошлой весной.

2. Анализ финансов в приложении банка. В данном примере статистическая информация - транзакции с карты, которые в последствии распределяются по категориям и обобщаются в диаграмму, по которой можно сделать выводы о тратах.



3. Измерения умных весов. Первичными данными в этом примере являются измерения веса, которые обобщаются в графики динамики веса, показатели ИМТ и пр.



2. Основные статистические понятия

Генеральная совокупность — совокупность всех потенциально возможных вариантов, которые можно получить при одинаковых условиях.

Выборка — данные, которые получены при наблюдениях. Размер выборки конечен и ограничен критериями — методами отбора.

Репрезентативность — понятие, которое говорит, насколько показательна выборка, реалистично ли в ней распределены варианты. Выборка считается репрезентативной, если в ней учтено множество параметров и она достоверно отражает генеральную совокупность.

Распределение — это описание того, с какой частотой в переменной встречаются определённые значения.

Числовые характеристики:

Среднее арифметическое — усредненное значение среди всех показателей.

Медиана — значение, которое находится посередине распределения.


Мода — значение, которое встречается в выборке чаще всего.

Размах — разница между минимальным и максимальным значением.

Дисперсия — отклонение значений от среднего арифметического.

Ниже рассмотрим на примере основные статистические понятия:

```
# Проведем исследование роста студентов Москвы. В данном случае
# генеральная совокупность - рост студентов во всех вузах Москвы.
# Выборка - рост студентов в аудитории (будет ли данная выборка
# репрезентативной?)
import numpy as np # Импорт библиотеки для работы с массивами
sample = np.array([166, 183, 152, 165, 171, 167, 180, 170, 155, 173])
#Сбор данных
import matplotlib.pyplot as plt # Загрузка библиотек визуализации
(установка через pip install "наименование пакета" в ячейке)
import seaborn as sns
# Визуализация графика распределения роста
sns.displot(data=sample)
```



```
print('Среднее:', np.mean(sample)) # Вычисление среднего значения
print('Медиана:', np.median(sample)) # Вычисление медианы
print('Стандартное отклонение:', np.std(sample)) # Вычисление
стандартного отклонения
print('Дисперсия:', np.var(sample)) # Вычисление дисперсии
```

Среднее: 168.2

Медиана: 168.5

Стандартное отклонение: 9.195651146058118

Дисперсия: 84.55999999999999


3. Виды распределений.

Распределение — это функция, которая показывает возможные значения переменной и частоту их появления. Она обеспечивает математическое описание поведения данных, указывая, где сосредоточено большинство точек данных и как они распределены. Распределения делятся на дискретные и непрерывные:

1. Дискретные распределения используются для описания событий с конечным или счетным числом исходов, например, успех или неудача, целое число (например, игра в рулетку, в кости), орёл или решка и т.д.

2. Непрерывные распределения используются для данных, значения которых могут принимать любое значение в некотором интервале. Например: температура, рост, вес, и т.д.

Примеры основных распределений:



Распределение данных играет важную роль в выборе методов для исследования. Выделяют параметрические и непараметрические методы:

1. Параметрические методы — это статистические методы, которые основаны на определённых предположениях о распределении данных. Эти методы обычно предполагают, что данные подчиняются известному распределению вероятностей, например нормальному распределению, и оценивают параметры этого распределения с помощью имеющихся данных.

2. Непараметрические методы — это статистические методы, которые не основаны на конкретных предположениях о распределении изучаемой совокупности. Эти методы часто называют «свободными от распределения», поскольку они не предполагают никаких предположений о форме распределения.

Работу с распределением данных рассмотрим в следующем пункте.

4. Алгоритм проведения анализа данных.

Основные этапы анализа данных:

1. **Сбор данных.** На данном этапе определяются источники данных и методы сбора. (Например, для социологического опроса подбирается группа респондентов и составляются вопросы)

2. **Предобработка данных.** Этап включает в себя чистку данных, анализ пропущенных значений, дубликатов, преобразование типов и т.д. (Например, при исследовании среднего дохода населения важно удалить выбросы - доход олигархов во избежание завышенных статистических показателей и представления смещенных результатов)

3. **Анализ данных.** Данный этап включает в себя применение статистических методов для выявления закономерностей в данных, классификаций и пр. (Например, прогнозирование дохода магазина на следующий год)

4. **Визуализация данных и интерпретация результатов для принятия решений.** (Например, в результате анализа были выявлены потенциальные клиенты для рассылки промокодов и привлечения их в магазин)

```
# Рассмотрим алгоритм проведения анализа данных на примере
# основная задача исследования - определить существует ли разница между
# весом пингвинов самок и самцов
import pandas as pd #Импортируем библиотеку для работы с таблицами
df = sns.load_dataset("penguins") #Загружаем датасет с исследованием
#пингвинов из библиотеки seaborn
df.head() #Выводим первые строки датасета для проверки импорта методом
.head()
```

	species	island	bill_length_mm	bill_depth_mm
0	Adelie	Torgersen	39.1	18.7
1	Adelie	Torgersen	39.5	17.4
2	Adelie	Torgersen	40.3	18.0
3	Adelie	Torgersen	Missing value	Missing value
4	Adelie	Torgersen	36.7	19.3

```
df.info() # Выводим основную информацию о датасете, в колонке Non-Null
Count можно заметить наличие пропущенных значений
# Для работы с пропущенными значениями можно использовать метод
.fillna(),
# либо удалить пропущенные значения если их мало и невозможно
восстановить
df = df[~df['sex'].isna()] # df['sex'].isna() - отбирает пропущенные
значения по полю 'sex',
# ~ перед условием обозначает логическое отрицание, df[<условие>]
возвращает необходимые строки

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 344 entries, 0 to 343
Data columns (total 7 columns):
#   Column                Non-Null Count  Dtype
---  -
0   species                344 non-null   object
1   island                  344 non-null   object
2   bill_length_mm          342 non-null   float64
3   bill_depth_mm           342 non-null   float64
4   flipper_length_mm       342 non-null   float64
5   body_mass_g             342 non-null   float64
6   sex                     333 non-null   object
dtypes: float64(4), object(3)
memory usage: 18.9+ KB
```

```
# вывод общей статистической информации о данных
df.describe()
```


	# bill_length_mm	# bill_depth_mm	# flipper_length_mm	# body_mass_g
count	333.0	333.0	333.0	333.0
mean	43.99279279279279	17.164864864864864	200.96696696696696	4207.057057057057
std	5.468668342647559	1.969235463199007	14.015765288287879	805.2158019428965
min	32.1	13.1	172.0	2700.0
25%	39.5	15.6	190.0	3550.0
50%	44.5	17.3	197.0	4050.0
75%	48.6	18.7	213.0	4775.0
max	59.6	21.5	231.0	6300.0

```
# Для применения статистических методов проверяем распределение данных на
нормальность
```

```
# Строим график распределения массы пингвинов (визуальный вариант
проверки)
```

```
sns.displot(data=df, x="body_mass_g", kde = 'True') # Указываем источник
data=df, ось x - "body_mass_g"
```

```
# Параметр kde = 'True' показывает график ядерной оценки плотности -
сглаживает данные и помогает оценить распределение наглядно
```



```

# Проверяем данные на нормальность тестом Шапиро-Уилка
# В данном тесте выдвигается нулевая гипотеза H0: "случайная величина
распределена нормально", альтернативная H1: "распределение не нормальное"
import scipy # Импортируем библиотеку со статистическими методами
stat, p = scipy.stats.shapiro(df['body_mass_g']) # проводим тест Шапиро-
Уилка, он возвращает значение статистики и p-value
# P-value - это минимальный уровень значимости, на котором нулевая
гипотеза может быть отвергнута.
# другими словами, p-value - это вероятность того, что нулевая гипотеза
жизнеспособна,
# чем выше p-value, тем лучше, если мы хотим, чтобы нулевая гипотеза не
была отвергнута.
print('Statistics=%.3f, p-value=%.3f' % (stat, p))
alpha = 0.05 # alpha - уровень значимости, который задается
самостоятельно, обычно используют alpha = 0.05
if p > alpha:
    print('Принять гипотезу о нормальности')
else:
    print('Отклонить гипотезу о нормальности')
# p-value=0, следовательно, нет оснований принимать нулевую гипотезу. В
исследовании используем непараметрические методы.

```

Statistics=0.958, p-value=0.000

Отклонить гипотезу о нормальности

```

# Далее нам необходимо определить существует ли разница между весом
пингвинов самок и самцов
# для этого можно рассчитать средние значения
df[['body_mass_g', 'sex']].groupby(by='sex').mean()
# видно, что вес самцов больше чем у самок, но можно ли данные результат
назвать статистическим значимым?
# т.е. можем ли мы сказать, что такие результаты не случайны и при
проведении других экспериментов не окажется, что вес самки больше?

```

sex	# body_mass_g
Female	3862.2727272727275
Male	4545.684523809524

```


# для задач проверки средних значений используется t-тест (для нормальных
данных) и U-критерий Манна - Уитни (если распределение неизвестно)
# H0: две группы имеют одинаковое распределение, H1: одна группа имеет
большие (или меньшие) значения, чем другая
male = df['body_mass_g'][df['sex']=='Male'] # массив с самцами
female = df['body_mass_g'][df['sex']=='Female'] # массив с самками
stat, p = scipy.stats.mannwhitneyu(male, female) # Используем метод
mannwhitneyu для проверки гипотезы
print('Statistics=%.3f, p-value=%.3f' % (stat, p))
alpha = 0.05
if p > alpha:
    print('Принять гипотезу об отсутствии различий')
else:
    print('Отклонить гипотезу об отсутствии различий')
# отклоняем нулевую гипотезу, следовательно, между весом самца и самки
есть статистическая разница

```

Statistics=20845.500, p-value=0.000

Отклонить гипотезу об отсутствии различий

```
# Визуализировать разницу можно при помощи графика ящика с усами  
sns.boxplot(data=df, x='sex', y='body_mass_g')
```



Задание 1 (2 балла)

1. Скачать данные по ссылке

<https://www.kaggle.com/datasets/efeyldz/customer-churn-and-segmentation-dataset-synthetic>;

2. Загрузить в python при помощи функции `pd.read_csv('<Название файла>')`;

3. Вывести диаграмму распределения для показателя `Annual_Income` (годовой доход), проверить данные на нормальное распределение;

4. С помощью функции `.groupby` вывести средние значения годового дохода для мужчин и женщин (`Gender`);

5. Сравнить средние значения годового дохода у мужчин и женщин при помощи статистического теста.

Задание 2 (2 балла)

1. Самостоятельно изучить понятие дисперсионного анализа;

2. Проверить различается ли годовой доход клиентов от уровня членства (`Membership_Level`).

Результаты представить в формате презентации.