

ДИСЦИПЛИНА	Базы данных и анализ промышленных данных
ИНСТИТУТ	Передовая инженерная школа
КАФЕДРА	Кафедра передовых технологий
ВИД УЧЕБНОГО МАТЕРИАЛА	Практическое занятие
ПРЕПОДАВАТЕЛЬ	Астафьев Р.У.
СЕМЕСТР	2 семестр, 2025 - 2026 гг.

Практическая работа 3


Разведочный анализ данных

Разведочный анализ данных (Exploratory Data Analysis, EDA) – это процесс анализа наборов данных для обобщения их основных характеристик, поиска трендов и взаимосвязей. Для разведочного анализа данных используют следующие инструменты и методы:

1. Описательная статистика — метод, который позволяет описать основные характеристики выборки данных. Описательная статистика включает в себя различные показатели, такие как среднее значение, медиана, дисперсия, стандартное отклонение, минимум, максимум, квартили и другие.

2. Визуализация данных, которая включает в себя создание графиков и диаграмм. Она помогает лучше понять распределения, корреляции и тренды, например, гистограммы, диаграммы рассеяния, ящики с усами.

3. Исследование связей, которое показывает влияние одних факторов на другие (например, высота и вес людей взаимосвязаны, т.е. при увеличении роста вес человека также увеличивается). Для исследования взаимосвязей рассчитывают коэффициент корреляции – это показатель, характеризующий силу статистической связи между двумя или несколькими случайными величинами. Значения коэффициента корреляции всегда расположены в диапазоне от -1 до 1, где 1 - сильная положительная корреляция (например, чем выше температура, тем больше мороженого продается), а -1 - сильная отрицательная корреляция (например, чем выше уровень образования, тем меньше уровень преступности). Промежуточные значения, близкие к 0, будут указывать на слабую корреляцию между переменными и, соответственно, низкую зависимость. Визуальное отображение взаимосвязей переменных:



Пример проведения разведочного анализа: представим, что у нас есть набор данных о продажах товаров в магазине. При проведении

разведочного анализа данных мы можем изучить, какие товары самые популярные, как цены на них изменяются, каковы средние продажи в разное время года и как коррелируют различные факторы (например, цена и количество продаж). В результате анализа мы можем выявить, например, что определенные товары продаются лучше в определенное время года или что цена оказывает значительное влияние на объем продаж.

Разберем пример проведения разведочного анализа по данным о поездках на такси:

```
import pandas as pd # Импортируем библиотеку для работы с датасетом
import seaborn as sns # Импортируем библиотеки для работы с визуализацией
import matplotlib.pyplot as plt
%matplotlib inline
sns.set_style("whitegrid") # Устанавливаем тему для графиков
sns.set_palette(sns.color_palette("icefire")) # Устанавливаем единую
палитру для всех визуализаций
df = sns.load_dataset("taxi") # Загружаем датасет о поездках на такси
df.head() # Проверяем загрузку
```

Показатели:

pickup - Время посадки

dropoff - Время высадки

passengers - К-во пассажиров

distance - Дистанция

fare - Оплата за проезд

tip - Чаевые

tolls - Пошлина

total - Итоговая сумма поездки

color - Цвет машины

payment - Вид оплаты

pickup_zone - Зона посадки

dropoff_zone - Зона высадки

pickup_borough - Район посадки

dropoff_borough - Район высадки

```
df.select_dtypes(include=['object']).describe() # Описательная статистика
для категориальных данных
# df.select_dtypes() обращается к переменным определенного типа
# Метод .describe() выводит описательную статистику по каждой переменной
```

	color	payment	pickup_zone	dropoff_zone	pickup_borough	dropoff_borough
count	6433	6389	6407	6388	6407	6388
unique	2	2	194	203	4	5
top	yellow	credit card	Midtown Center	Upper East Side North	Manhattan	Manhattan
freq	5451	4577	230	245	5268	5206

```
df.select_dtypes(include=['float64', 'int64']).describe() # Описательная
статистика для числовых данных
```

	passengers	distance	fare	tip	tolls	total
count	6433.000000	6433.000000	6433.000000	6433.000000	6433.000000	6433.000000
mean	1.539251	3.024617	13.091073	1.97922	0.325273	18.517794
std	1.203768	3.827867	11.551804	2.44856	1.415267	13.815570
min	0.000000	0.000000	1.000000	0.00000	0.000000	1.300000
25%	1.000000	0.980000	6.500000	0.00000	0.000000	10.800000
50%	1.000000	1.640000	9.500000	1.70000	0.000000	14.160000
75%	2.000000	3.210000	15.000000	2.80000	0.000000	20.300000
max	6.000000	36.700000	150.000000	33.20000	24.020000	174.820000

`df.dtypes` # Типы данных датафрейма можно посмотреть при помощи команды `.dtypes`

```

pickup          datetime64[ns]
dropoff         datetime64[ns]
passengers              int64
distance             float64
fare                 float64
tip                  float64
tolls                float64
total               float64
color               object
payment             object
pickup_zone         object
dropoff_zone        object
pickup_borough      object
dropoff_borough     object
dtype: object

```

Визуализация данных в разведочном анализе данных начинается с построения распределения при помощи гистограмм
 # Гистограмма - визуальный элемент показывающий, с какой частотой один и тот же параметр принимает определенные значения.


Рассмотрим построение на примере показателя `payment` (вид оплаты)
`df['payment'].value_counts()` # метод `.value_counts()` выводит частоту для каждого значения переменной

```


payment
credit card    4577
cash           1812
Name: count, dtype: int64

```


Построение гистограммы
`sns.countplot(df, x='payment')`
 # По данному графику можем сделать вывод, что кредитными картами пассажиры пользуются в 2 раза чаще




```
# Также при построении гистограмм можно добавлять различные срезы в
данных при помощи атрибута hue = <Переменная>
sns.countplot(df, x='payment', hue = 'color')
# В данном случае можем сделать вывод, что чаще всего к пассажирам
приезжает желтая машина и при окончании поездки они расплачиваются картой
```




```
# Построим гистограмму для числовой переменной total, параметр bins
задает число разбиений
sns.histplot(df, x='total', bins = 30)
# По данной диаграмме можем сделать вывод, что распределение
асимметричное, большинство заказов такси стоят до 25$
# Длинный хвост у распределения может указывать на наличие выбросов, либо
поездку на большое расстояние
```




```
# Для исследования взаимосвязей рассмотрим визуализацию тепловой карты
(heatmap)
# Данные для построения диаграммы - коэффициенты корреляции между
переменными, вычисляется при помощи функции .corr()
# Параметры annot и cmap добавляют подписи и меняют цвет
sns.heatmap(df[['distance', 'fare', 'tip', 'tolls', 'total']].corr(), an-
not=True, cmap="icefire")
# По графику заметим, что обратной корреляции в данных не наблюдается
# Красный цвет означает сильную взаимосвязь, голубой - более слабую
```



```
# Рассмотрим более детально взаимосвязь переменных fare (стоимость
поездки) и distance (дистанция) (коэффициент корреляции составляет 0,97 -
сильная корреляция)
# Для этого построим диаграмму рассеяния, где по шкале x - стоимость
поездки, по y - дистанция
sns.scatterplot(df, x="fare", y="distance")
# График подтверждает взаимосвязь: чем больше дистанция поездки, тем выше
ее стоимость
```



```
# Также рассмотрим взаимосвязь переменных tip (чаевые) и distance
(дистанция) (коэффициент корреляции составляет 0,45 - средняя корреляция)
sns.scatterplot(df, x="distance", y="tip")
# По графику видно, что наблюдения располагаются более разрозненно, также
присутствует много нулевых значений
```



Также в рамках разведочного анализа данных может возникнуть потребность в группировке данных по определенному признаку для их обобщения. Для этого используется функция **groupby**, которая разделяет датасет по заданным группам. Для обобщения используются функции агрегирования, которые принимают несколько отдельных значений и возвращают сводные данные (среднее, медиана, минимум, максимум).

```
# Например, рассмотрим медианное значение чаевых, оставляемых в такси
разного цвета
# Для этого в параметр by функции groupby передаем столбец color, по
которому будет происходить разделение на группы (желтые, зеленые)
# .median() задает агрегирующую функцию
df[['color', 'tip']].groupby(by= 'color').median()
```

tip	
color	
green	0.00
yellow	1.95

```
# Также в groupby можно передавать несколько столбцов
# Посмотрим, какая средняя стоимость поездки в топ-10 зонах и районах
# Функция sort_values сортирует значения, а параметр ascending задает
направление сортировки
df[['pickup_borough', 'pickup_zone', 'total']].groupby(by=
['pickup_borough', 'pickup_zone']).mean().sort_values(by = 'total', as-
cending = False).head(10)
```

		total
pickup_borough	pickup_zone	
Queens	East Flushing	90.500000
	Flushing Meadows-Corona Park	75.560000
	JFK Airport	55.336954
	Douglaston	53.730000
	Maspeth	52.040000
Bronx	Bronx Park	50.330000
Queens	Cambria Heights	46.903333
Bronx	Crotona Park East	44.870000
Queens	Howard Beach	44.800000
Brooklyn	Sunset Park West	43.086667

Задание (4 балла)

1. Самостоятельно выбрать датасет на любую тему, который будет содержать числовые и категориальные переменные;
2. Очистить данные от дубликатов, выбросов и т.д.;
3. Провести разведочный анализ данных с выводом описательных статистик, визуализаций и функции `groupby`, описать полученные выводы;

Результаты представить в формате `.ipynb`.