

ДИСЦИПЛИНА	Базы данных и анализ промышленных данных
ИНСТИТУТ	Передовая инженерная школа
КАФЕДРА	Кафедра передовых технологий
ВИД УЧЕБНОГО МАТЕРИАЛА	Практическое занятие
ПРЕПОДАВАТЕЛЬ	Астафьев Р.У.
СЕМЕСТР	2 семестр, 2025 - 2026 гг.

Практическая работа 8

Факторный анализ: методы предпосылки, методы проведения, анализ результатов.

Факторный анализ – метод анализа данных, который используется для выявления скрытых факторов, влияющих на наблюдаемые переменные и уменьшения размерности массива данных.


Фактор – скрытая переменная, объясняющая связь между совокупностью переменных.

Например, у нас есть данные о продаже квартир: 1 – удалённость от метро, 2 – наличие огнетушителей, 3 – наличие ремонта, 4 – количество открытых люков перед подъездом.

При применении факторного анализа обнаруживается сильная зависимость между показателями 1 и 3, 2 и 4, тогда мы можем выделить следующие факторы: комфортабельность (показатели 1 и 3), безопасность (показатели 2 и 4), при этом сохранив влияние всех переменных.

Применение методов факторного анализа выглядит следующим образом:

Первоначальный массив данных:



Массив данных после выделения факторов:



Условия проведения факторного анализа:

1. Все признаки являются количественными переменными
2. Число наблюдений больше числа переменных
3. Номинальные переменные переведены в дихотомические
4. Выборка однородна
5. Факторный анализ осуществляется по коррелирующим переменным, т.к. при проведении факторного анализа в факторы объединяются переменные с высокой степенью зависимости.

Факторный анализ включает в себя большое количество методов, которые используются в различных областях (экономика, психология, социология и др.), но самыми распространенными являются следующие:

1. Метод главных компонент (PCA) заключается в поиске линейных комбинаций переменных, которые объясняют наибольшую долю изменчивости данных. Линейные комбинации называются главными компонентами. Метод PCA позволяет выделять наиболее важные факторы в данных основываясь на корреляционных зависимостях.

2. Метод максимального правдоподобия (MLE) позволяет определить значение параметров, наиболее вероятно соответствующее наблюдаемым данным.

3. Метод наименьших квадратов (PLS) используется при решении задач регрессии с большим объемом входных данных.

Рассмотрим основные шаги проведения факторного анализа методом главных компонент:

1. Нормализация данных

2. Построение ковариационной матрицы данных (ковариация схожа с корреляцией, но не нормируется, т.е. коэффициент не находится в пределах от -1 до +1)

3. Вычисление собственных значений и собственных векторов этой матрицы (собственным вектором матрицы называется такой вектор, который при умножении с матрицей превращается в самого же себя с числовым коэффициентом. Числовой коэффициент называют собственным числом матрицы)

4. Выбрать собственные значения, которые объясняют наибольшую долю изменчивости данных.

5. Вычисление главных компонент

```
import pandas as pd # Импортируем библиотеки для работы с данными
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
df=pd.read_csv('Sleep_health_and_lifestyle_dataset.csv') # Загружаем
датасет о качестве сна и уровне физической активности
# Подробное описание данных:
https://www.kaggle.com/datasets/uom190346a/sleep-health-and-lifestyle-dataset/data
df.head() # Проверям загрузку датасета
```


	Person ID	Gender	Age	Occupation	Sleep Duration	Quality of Sleep	Physical Activity Level	Stress Level	BMI Category	Blood Pressure	Heart Rate	Daily Steps	Sleep Disorder
0	1	Male	27	Software Engineer	6.1	6	42	6	Overweight	126/83	77	4200	NaN
1	2	Male	28	Doctor	6.2	6	60	8	Normal	125/80	75	10000	NaN
2	3	Male	28	Doctor	6.2	6	60	8	Normal	125/80	75	10000	NaN
3	4	Male	28	Sales Representative	5.9	4	30	8	Obese	140/90	85	3000	Sleep Apnea
4	5	Male	28	Sales Representative	5.9	4	30	8	Obese	140/90	85	3000	Sleep Apnea

```
# Для поиска факторов выберем только числовые переменные
df = df[['Age', 'Sleep Duration', 'Quality of Sleep', 'Physical Activity Level', 'Stress Level', 'Heart Rate', 'Daily Steps']]
```

```
# Приведем данные к единой шкале при помощи StandardScaler
from sklearn.preprocessing import StandardScaler # Импортируем метод
scaler = StandardScaler() # Создаем объект
scaled_features = scaler.fit_transform(df) # Нормализуем данные
df = pd.DataFrame(scaled_features, index=df.index, columns=df.columns) #
Записываем нормализованные данные в датафрейм
df.head()
```

	Age	Sleep Duration	Quality of Sleep	Physical Activity Level	Stress Level	Heart Rate	Daily Steps
0	-1.753096	-1.298887	-1.098280	-0.825418	0.347021	1.654719	-1.619584
1	-1.637643	-1.173036	-1.098280	0.039844	1.475592	1.170474	1.970077
2	-1.637643	-1.173036	-1.098280	0.039844	1.475592	1.170474	1.970077
3	-1.637643	-1.550588	-2.771424	-1.402260	1.475592	3.591698	-2.362273
4	-1.637643	-1.550588	-2.771424	-1.402260	1.475592	3.591698	-2.362273

```
# Построим матрицу ковариаций для проверки наличия связей
plt.figure(figsize=(15, 6))
sns.heatmap(df.cov(), annot=True, cmap="Blues") # Метод df.cov()
возвращает ковариационную матрицу
# По ковариационной матрице делаем вывод, что между переменными есть
связь
```



```
# Импортируем библиотеки для проведения факторного анализа
from factor_analyzer import FactorAnalyzer
from factor_analyzer.factor_analyzer import calculate_kmo
from factor_analyzer.factor_analyzer import calculate_bartlett_sphericity
```

```
# Проверим подходят ли данные для факторного анализа при помощи Критерия
Бартлетта
chi_square_value, p_value = calculate_bartlett_sphericity(df)
print("Статистика:", chi_square_value, "P-value:", p_value)
# p_value равно нулю, следовательно данные подходят, тест статистически
значим
```

Статистика: 2236.092733567358 P-value: 0.0

```
# Тест Кайзера-Мейера-Олкина
kmo_all, kmo_model = calculate_kmo(df)
print("КМО:", kmo_model)
# Значение близкое к 0,6 говорит об удовлетворительной адекватности
данных
```

КМО: 0.6149594748972398

```
model = FactorAnalyzer() # Создаем объект факторного анализа
```

```

model.fit(df) # Обучаем данные
ev, v = model.get_eigenvalues() # Получаем собственные значения и
собственные вектора
ev

```

```


array([3.48370838, 1.82328943, 0.79495298, 0.5956675 , 0.1573186 ,
       0.08862156, 0.05644155])

```

```

# Для определения числа факторов используем график каменистой осыпи.
Метод заключается в поиске точки, где убывание собственных значений
замедляется наиболее сильно
plt.scatter(range(1, df.shape[1]+1), ev)
plt.plot(range(1, df.shape[1]+1), ev)
plt.title('График каменистой осыпи')
plt.xlabel('Факторы')
plt.ylabel('Собственные значения')
# По данному графику можем определить, что для нас будет достаточно 2-3
фактора

```



```

# Проведем новый факторный анализ с известным числом фокторов
model = FactorAnalyzer()
model.set_params(n_factors=2, rotation='varimax') # Настраиваем к-во
факторов
model.fit(df)
loadings = model.loadings_ # Сохраним корреляцию между переменными и
факторами

```


```

df_fa = pd.DataFrame(loadings)
df_fa.columns=[ 'Factor1', 'Factor2']
df_fa

```

	Factor1	Factor2
0	0.432141	0.122496
1	0.854998	0.076542
2	0.996891	0.089134
3	0.112445	1.001760
4	-0.956362	0.115429
5	-0.647160	0.107791
6	-0.052371	0.761649

```
# Визуализируем тепловую карту для наглядности
df_fa_pivot = (df_fa.pivot_table(index=df.columns))
plt.figure(figsize=(5, 10))
sns.heatmap(df_fa_pivot, annot=True, cmap="Blues" )
# В результате мы можем сделать вывод, что на первый фактор влияет
# возраст, качество сна и его продолжительность,
# на второй фактор оказывают влияние переменные связанные с общим
# состоянием организма и уровнем физической активности
```



```
# Вывести факторы можно с помощью метода model.transform()
model.transform(df)[:10]
array([[ -0.6222333 , -0.94458952],
       [-0.79443042, -0.74696521],
       [-0.79443042, -0.74696521],
       [-2.28152615, -2.0603003 ],
       [-2.28152615, -2.0603003 ],
       [-2.28152615, -2.0603003 ],
       [-0.73460004, -1.12466836],
       [-0.4526812 ,  0.72561469],
       [-0.4526812 ,  0.72561469],
       [-0.4526812 ,  0.72561469]])
```

Задание (4 балла)

1. Скачать данные по ссылке

<https://www.kaggle.com/datasets/teejmahal20/airline-passenger-satisfaction?select=train.csv>;

2. Провести очистку и нормализацию данных;
3. Рассчитать значения критерия Бартлетта и Кайзера-Мейера-Олкина;
4. Построить график каменистой осыпи;
5. Провести факторный анализ, описать характеристики полученных факторов.

Результаты представить в формате презентации.