

ДИСЦИПЛИНА	Базы данных и анализ промышленных данных
ИНСТИТУТ	Институт перспективных технологий и индустриального программирования
КАФЕДРА	Кафедра индустриального программирования
ВИД УЧЕБНОГО МАТЕРИАЛА	Практическое занятие
ПРЕПОДАВАТЕЛЬ	Григорьева Анастасия Алексеевна
СЕМЕСТР	2 семестр, 2025 - 2026 гг.

Практическая работа 13

Работа с выбросами при помощи ML.

Выброс (аномалия) – это наблюдение, которое отличается от остальных данных. Причины появления выбросов могут быть разными: ошибки сбора, редкие наблюдения и т.д.


В традиционной статистике для обнаружения выбросов часто используют методы, основанные на предположении о нормальном распределении, как правило 3-х сигм, либо межквартильный размах. Однако в многомерных данных эти методы работают плохо. Рассмотрим основные методы работы с выбросами:

1. Пространственные данные

— Isolation Forest: обнаруживает аномалии путем изоляции выбросов от нормальных точек с помощью ансамбля деревьев изоляции.

— Local Outlier Factor (LOF): сравнивает локальную плотность объекта с плотностью его соседей. Выбросы находятся в областях с аномально низкой плотностью.

— One-Class SVM (OCSVM): обучается на «нормальных» данных, строя границу, отделяющую их от всего остального пространства.



— Autoencoders (AE): нейросеть учится восстанавливать «нормальные» данные. Если ошибка восстановления (MSE) для нового объекта высока — это выброс.

— DBSCAN: Кластеризация, при которой точки, не попавшие ни в один кластер, считаются шумом (выбросами).

2. Временные ряды

— Скользящие окна: является самым предпочтительным методом для работы с временными рядами, для удаления выбросов можно использовать функцию медианы в окне, т.к. она более устойчива к выбросам.

— ML на признаках: превращение ряда в таблицу, содержащую лаг-признаки (для которых берутся значения на предыдущих шагах временного ряда) и значения скользящих окон, затем применение моделей (Isolation Forest, LOF и т.д.).


— Построение прогнозных моделей: на основе предыдущих наблюдений предсказывается следующая часть временного ряда, которая сравнивается с фактическими значениями, где аномальное значение ошибки может свидетельствовать о выбросе. В данном методе могут использоваться модели регрессии, ARIMA и пр., а также модификации рекуррентных нейронных сетей, такие как LSTM и GRU, которые способны запоминать длинные последовательности.

Рассмотрим применение модели Isolation Forest на практике:

```
import numpy as np # Импортируем библиотеки
import pandas as pd
import seaborn as sns
from sklearn.ensemble import IsolationForest
from sklearn.preprocessing import StandardScaler
#Рассмотрим данные о цене и площади домов
df = pd.read_csv('data.csv') # Данные:
https://www.kaggle.com/datasets/pranavshinde36/india-house-rent-prediction
df.head() # Проверяем загрузку датасета
```

	house_type	locality	city	area	# beds
0	2 BHK Flat for Rent in Oberoi Woods	Goregaon East	Mumbai		897.0
1	1 BHK Flat for Rent in Sapphire Lakes	Powai	Mumbai		490.0
2	1 BHK House for Rent in Mundhwa F	Mundhwa	Pune		550.0
3	2 BHK Flat for Rent in Hingna, Nagpur	Hingna	Nagpur		1000.0
4	1 BHK Flat for Rent in Unique Star Hs	Mira Road	Mumbai		595.0

```
sns.scatterplot(data=df, x="rent", y="area") # По графику видим минимум 3 выброса
```



```

X = df[['rent', 'area']] # Перенесем необходимые показатели в новую
переменную
X_scaled = StandardScaler().fit_transform(X) # Стандартизируем данные


model = IsolationForest(contamination=0.01, random_state=42) # Задаем
параметры модели, contamination - доля выбросов
y_pred = model.fit_predict(X_scaled) # Предсказываем значения для
определения выбросов: 1 - норма, -1 - выброс

# Смотрим на результаты работы алгоритма
print('Всего точек:', len(X))
print('Выбросов найдено:', np.sum(y_pred == -1))

Всего точек: 7691
Выбросов найдено: 77

# Визуализируем результат работы алгоритма
df_outlier = pd.DataFrame(np.column_stack([X_scaled, y_pred]),
columns=['rent', 'area', 'is_outlier'])
sns.scatterplot(data = df_outlier[df_outlier['is_outlier']==1], x="rent",
y="area")
sns.scatterplot(data = df_outlier[df_outlier['is_outlier']==-1],
x="rent", y="area", color='red', label='Выбросы')

```



Задание 1 (4 балла)

1. Самостоятельно выбрать датасет пространственных данных на любую тему, который будет содержать выбросы;
2. Используя 3 любых метода, удалить выбросы из выборки;
3. Визуализировать и сравнить работу алгоритмов.

Задание* (2 балла)

1. Самостоятельно изучить критерий Граббса, тест Диксона;
2. Проверить найденные выбросы из задания 1 статистическими тестами.

Задание* (2 балла)

1. Самостоятельно выбрать датасет с временной составляющей, который будет содержать выбросы;
2. Удалить выбросы методами скользящего среднего и ML (3 модели);
3. Сравнить и визуализировать работу алгоритмов.

Результаты представить в формате презентации.